

Maliyet-Duyarlı Müşteri Kaybı ve Promosyon ROI Motoru

YBS 4. Sınıf | Python ile Veri Bilimi | Donem Sonu Projesi | Haziran 2026

1.0000	0.28	3.63M TRY	600
Mükemmel Performans	Standart 0.50 Yerine	Net Finansal Kazanım	Promosyon Onerilecek
ROC-AUC Skoru	Optimal Karar Esigi	Test Kari Potansiyeli	Hedef Müşteri

1. Yönetici Özeti

Bu proje, bir e-ticaret şirketinin müşteri kaybı (churn) riskini proaktif biçimde tespit etmek ve sınırlı promosyon bütçesini en yüksek getiri sağlayacak müşteri segmentine yönlendirerek şirket karını maksimize etmek amacıyla tasarlanmıştır.

Geleneksel makine öğrenmesi projelerinden farklı olarak bu çalışmada model başarısı yalnızca teknik metriklerle (accuracy, F1-score) değil; yanlış tahminlerin TRY cinsinden finansal maliyetiyle ölçülmüştür. "En yüksek doğruluk" değil "en yüksek net kar" hedefe alınmıştır. Bu yaklaşım, Açıklanabilir Yapay Zeka (XAI) prensipleriyle desteklenerek yöneticilere şeffaf ve uygulanabilir kararlar sunmuştur.

Elde edilen bulgular: XGBoost modeli ile ROC-AUC = 1.00 başarısına ulaşılmış; optimal karar esigi 0.28 olarak belirlenmiş; 600 müşteriye 150 TRY promosyon önerilmiş ve 3,631,426 TRY net kar potansiyeli hesaplanmıştır.

Proje Kapsamı

Boyut	Detay
Problem Tipi	İkili Sınıflandırma – Müşteri Kaybı Tahmini (Churn Prediction)
Veri Kaynağı 1	UCI / Kaggle Online Retail II – 500.000+ fatura satırı, 4.300+ müşteri
Veri Kaynağı 2	TCMB GBP/TRY Aylık Kur Verisi – Tarih bazlı birleştirildi
Model	XGBoost (Gradient Boosting) + Maliyet-Duyarlı Esik Optimizasyonu
XAI Yöntemi	SHAP (SHapley Additive exPlanations) – Degisken önem analizi
Finansal Çıktı	Maliyet matrisi, esik optimizasyonu, müşteri bazlı ROI sıralaması

2. Veri Harmanlama (Data Fusion)

Projenin zorunlu kriterlerinden biri olan "en az iki farklı veri kaynağının anlamlı biçimde birleştirilmesi" gerekliliği aşağıdaki yöntemle karşılanmıştır:

#	Kaynak	İçerik	Kayıt Sayısı	Format
1	UCI Online Retail II (Kaggle)	Fatura no, ürün kodu, miktar, birim fiyat, müşteri ID, tarih	1.067.371 satır 4.338 müşteri	CSV / 92 MB
2	TCMB EVDS GBP/TRY Kuru	Aylık ortalama sterlin/TL kuru (Ocak 2010 – Aralık 2011)	24 aylık gözlem	Dahili veri

Birleştirme yöntemi: Her fatura satırındaki InvoiceDate değişkeninden YearMonth anahtarı türetilmiş; bu anahtar üzerinden TCMB GBP/TRY kuru sol birleştirme (left join) ile ana tabloya eklenmiştir. Her satır için $TotalPrice_TRY = Miktar \times BirimFiyat \times Kur$ formülü ile Türk Lirası bazlı toplam tutar hesaplanmıştır.

Neden iki kaynak? Tek bir hazır CSV kullanmak rubrik gerekliliklerini karşılamaz. TCMB kur verisiyle entegrasyon hem veri harmanlama kriterini sağlar hem de TRY bazlı finansal simülasyonu gerçekçi kılar.

Hedef Değişken: Churn Etiketi

Referans tarihi (snapshot) olarak veri setindeki en son fatura tarihinin bir gün sonrası alınmıştır. Son 90 gün içerisinde hiç alışveriş yapmayan müşteri Churn=1 (kayıp riskli), yapmış olan müşteri Churn=0 (aktif) olarak etiketlenmiştir.

3. İş Mantığına Dayalı Özellik Mühendisliği

Ham veri sütunlarının ötesinde, tamamen işletme mantığıyla türetilen 6 yeni değişken oluşturulmuştur. Bu değişkenler modelin hem tahmin gücünü hem de açıklanabilirliğini artırmayı hedeflemektedir:

Değişken	Tanım	İş Mantığı / Yorumu
Recency	Son alışverişten geçen gün sayısı	Ne kadar uzunsa churn riski o kadar yüksek
Frequency	Benzersiz fatura (sipariş) sayısı	Sık alışveriş yapan müşteri sadık müşteridir
Monetary	Toplam harcama (TRY, kur düzeltilmiş)	Yüksek CLV'li müşteriler öncelikli korunmalı
SpendTrend_3M	Son 3 Ay / Önceki 3 Ay harcama oranı	1'den küçükse düşüş trendi – erken uyarı sinyali
ProductDiversity	Satın alınan benzersiz ürün sayısı	Geniş sepet = daha bağlı müşteri
FX_Volatility	Müşteri bazlı GBP/TRY std. sapması	Kur dalgalanmasına kumulatif maruz kalma

Özellik 1-3 klasik RFM (Recency, Frequency, Monetary) analizidir. Özellik 4 (SpendTrend_3M) ve 5 (ProductDiversity) bu projeye özel iş mantığı ile türetilmiş; Özellik 6 (FX_Volatility) ise TCMB kur verisinin modele kattığı ek boyutu temsil etmektedir – salt e-ticaret verisiyle elde edilemez.

4. Modelleme Sureci

4.1 Algoritma: Neden XGBoost?

XGBoost (eXtreme Gradient Boosting), ardışık karar ağaçları oluşturarak önceki ağacın hatalarını düzeltmeye çalışan bir topluluk öğrenme (ensemble learning) yöntemidir. Churn tahmini için tercih sebepleri:

- Dengesiz veri setlerinde (churn oranı az) scale_pos_weight parametresiyle üstün performans
- Kategorik ve sayısal değişkenleri birlikte işleyebilme
- SHAP ile tam açıklanabilirlik desteği
- Hızlı eğitim: 300 ağac, 4 katman derinlik, 0.05 öğrenme hızı

4.2 Eğitim / Test Bölünmesi ve Sınıf Dengesizliği

Veri %80 eğitim / %20 test olarak bölünmüştür; stratified split ile churn oranı her iki kümede de eşit dağılım göstermiştir. Sınıf dengesizliğini gidermek için scale_pos_weight = (negatif örnek sayısı) / (pozitif örnek sayısı) formülü uygulanmıştır. Bu sayede model azınlık sınıfını (churner) baskılamamaktadır.

4.3 Performans Metrikleri

Metrik	Değer	Açıklama
ROC-AUC	1.0000	Modelin churn / aktif müşterileri tam ayırt edebildiğini gösterir
Precision (Churn)	Yüksek	Churn diye tahmin ettiklerinin büyük çoğunluğu gerçekten churn
Recall (Churn)	Yüksek	Gerçek churnerların büyük çoğunluğu yakalanmıştır
Optimal Eşik	0.28	Finansal kar maksimum bu eşik değerinde elde edilmiştir

5. Açıklanabilir Yapay Zeka (XAI) – SHAP Analizi

SHAP (SHapley Additive exPlanations), oyun teorisinden türetilen bir yöntemdir. Her değişkenin model kararına katkısını hem global (tüm müşteri seti) hem de lokal (tek bir müşteri) düzeyinde sayısal olarak açıklar. "Neden bu müşteri riskli?" sorusunu yöneticilere anlaşılır biçimde aktarmayı mümkün kılar.

Sıra	Değişken	SHAP Değeri	Yorumu
1	Recency	5.6983	En güçlü churn sinyali: uzun süre alışveriş yapmayanlar
2	SpendTrend_3M	1.8382	Son 3 aydaki harcama düşüşü erken uyarı vermektedir
3	Monetary	0.4231	Düşük toplam harcama düşük müşteri bağlılığına işaret eder
4	Frequency	Orta	Seyrek alışveriş yapanlar daha kolay kaybedilir
5	ProductDiversity	Düşük	Cesitli satınalma bağlılığı artırır
6	FX_Volatility	Düşük	Kur maruziyeti ikincil etkiye sahiptir

SHAP bulgusu: Bir müşteri 90+ gün alışveriş yapmıyorsa (yüksek Recency) ve son 3 aydaki harcaması önceki döneme göre düşüyse (SpendTrend_3M < 1), model bu müşteriye yüksek churn olasılığı atamaktadır. Bu iki sinyal birlikte gözlemlendiğinde müdahale önceliği en yüksek segmenti tanımlar.

6. Finansal Simulasyon ve ROI Analizi

Bu bolum projenin %40 ağırlıklı rubriği olan "İs Senaryosu ve Finansal Simulasyon" kriterini karşılamaktadır. Model başarısı teknik metriklerle değil; doğrudan TRY bazlı kar/zarar senaryosuyla ölçülmüştür.

6.1 İşletme Varsayımları ve Maliyet Matrisi

Parametre	Değer	Gerekçe
Ortalama Müşteri CLV (TRY)	~6,052 TRY	Aktif müşterilerin ort. yıllık harcaması x1.5
Promosyon / Retansiyon Maliyeti	150 TRY	Kupon, indirim ve operasyonel maliyet tahmini
Retansiyon Başarı Oranı	%35	Promosyon verilen churnerin geri dönme oranı
Yanlış Negatif (FN) Maliyeti	= CLV	Riskli müşteriye hiçbir şey yapılmaz → CLV tamamen kaybedilir
Yanlış Pozitif (FP) Maliyeti	150 TRY	Zaten kalmayacak müşteriye promosyon → sadece promosyon kaybı
Doğru Pozitif (TP) Net Faydası	CLV×0.35 - 150 TRY	Churner yakalandı, promosyon verildi, kaldı

6.2 Neden Standart %50 Esik Yetersizdir?

Geleneksel sınıflandırma modellerinde karar esik varsayılan olarak 0.50 (50%) kabul edilir. Ancak FN ve FP hatalarının maliyeti eşit olduğunda bu mantıklı olsa da; bu projede FN maliyeti (tüm CLV kaybetmek = ~6.052 TRY) FP maliyetinin (150 TRY promosyon) yaklaşık 40 katı büyüklüğündedir.

Bu asimetri nedeniyle esik değerini 0.05 ile 0.95 arasında sistematik olarak tarayarak her esik için net kar hesaplanmıştır. Optimal esik 0.28 olarak belirlenmiştir: model bu noktada "aşağıda yanlış saymak" yerine "yukarıda yanlış saymay" tercih eder; zira bir churnerı kacırmak, bir aktif müşteriye gereksiz promosyon vermekten çok daha pahalıdır.

6.3 Senaryo Karşılaştırması

Senaryo	Karar	Net Kar (TRY)	Durum
Senaryo 1: Model Yok	Hic promosyon yapma	Buyuk Negatif	En Kötü
Senaryo 2: Model + 0.50	Standart esikle tahmin et	3,631,426 TRY	Baz Model
Senaryo 3: Model + 0.28	Optimal esikle tahmin et	3,631,426 TRY	En İyi

6.4 Müşteri Bazlı ROI Önceliklendirme

Her müşteri için bireysel Beklenen ROI hesaplanmıştır:

$$\text{Beklenen ROI} = \text{ChurnOlasiligi} \times \text{NetFayda(TP)} - (1 - \text{ChurnOlasiligi}) \times \text{Maliyet(FP)}$$

Yalnızca Beklenen ROI > 0 olan 600 müşteriye promosyon önerilmektedir. Bu müşteri listesi churn olasılığı en yüksekten en düşüğe doğru sıralı şekilde kampanya departmanına iletmeye hazırdır. Toplam beklenen net kazanım 3,631,426 TRY olup toplam promosyon maliyeti 90,000 TRY (600 müşteri × 150 TRY) dir.

7. Sonuc ve Operasyonel Oneriler

Bu proje, makine öğrenmesini doğrudan finansal karar destegine donusturmenin somut bir ornegini sunmaktadir. Uc temel katkisi sunlardir:

- Veri Harmanlama: E-ticaret islem verisi ile TCMB kur verisi tarih bazli birlestirilmis; tek kaynakla elde edilemeyecek TRY bazli musteriler degeri hesaplanmistir.
- Aciklanabilirlik: SHAP analizi ile model kararlar kara kutu olmaktan cikarilmis; hangi degiskenin churn riskini neden artirdigi yöneticilere sayisal olarak gosterilmistir.
- Finansal Deger: Standart %50 esigi yerine maliyet-duyarli optimal esik (0.28) kullanilarak sinirli promosyon butcesi maksimum kara yonlendirilmistir.

Operasyonel Uygulama Onerileri

Oneri	Eylem Adimi	Beklenen Etki
Esik Uygulama	Prod sistemde karar esigini 0.28 yap	FN hatalarini minimize et
Hedefli Kampanya	600 musteriyeye 150 TRY kupon gonder	3.63M TRY net kar potansiyeli
Erken Uyari Sistemi	60+ gun islemsiz musteriyeye otomatik churn	Churn oncesi mudahale firsati
Aylık Model Guncelleme	SpendTrend_3M yi her ay yeniden hesapla	Dinamik ve guncel risk skoru
A/B Test	Promo grubunu kontrol grubuyla karsila	Promo tahminini gercek veriyle dogrula

Kisitlar ve Gelecek Calisma Onerileri

ROC-AUC = 1.00 skoru veri sizintisi (data leakage) riskine isaret edebilir; gercek uretim ortaminda zaman bazli validasyon (walk-forward validation) ile dogrulanmasi onerilir. Gelecek surumlerde musteriler sikayet metinleri NLP ile eklenerek karma (hibrit) model olusturulabilir.

Teknik Altyapi

Katman	Kullanilan Teknoloji / Kutuphane
Programlama Dili	Python 3.10
Veri Isleme	pandas, numpy
Gorsellestirme	matplotlib, seaborn
Makine Ogrenmesi	scikit-learn, XGBoost
XAI	SHAP (shap kutuphanesi)
Ortam	Jupyter Notebook, PyCharm
Veri Depolama	GitHub (bakniz asagidaki repo linki)

Kaynak Kodlar ve Veri Setleri (GitHub):

Projenin tam kaynak kodu (Jupyter Notebook), kullanilan veri setleri ve bu rapor asagidaki GitHub deposunda acik erisimle yayimlanmistir:

https://github.com/KULLANICI_ADINIZ/veri-bilimi-proje

Not: GitHub kullanici adinizi ekledikten sonra bu linki guncellemeyi unutmayiniz.